Zadanie nr 1 - trening neuronu liniowego

Inteligentna Analiza Danych

Łukasz Centkowski 264303
Maciej Dominiak 264307

25 października 2026

1 Cel zadania

Celem zadania było ustalenie, od czego zależy jednoznaczność wag końcowych neuronu liniowego trenowanego wieloma wzorcami oraz czy skuteczny trening jest w ogóle osiągalny. Oba pytania badano w trzech konfiguracjach różniących się relacją liczby wag N do liczby wzorców M, a uzyskane obserwacje zinterpretowano przez pryzmat równoważności treningu z zadaniem rozwiązywania układu równań liniowych.

2 Wstęp teoretyczny

Trening neuronu liniowego regułą delty jest gradientową minimalizacją błędu średniokwadratowego [2]. Ponieważ wyjście neuronu zależy od wag liniowo, żądanie zerowego błędu na wszystkich wzorcach sprowadza się do układu równań

$$\mathbf{X}\mathbf{w} = \mathbf{t}, \qquad \mathbf{X} \in \mathbb{R}^{M \times N}, \tag{1}$$

gdzie wierszami $\mathbf{X}$ są wzorce treningowe, a wagi pełnią rolę niewiadomych [1]. Liczba wzorców to liczba równań, liczba wag to liczba niewiadomych.

Każda poprawka wag jest wielokrotnością prezentowanego wzorca, więc przyrost $\mathbf{w} - \mathbf{w}_0$ leży w przestrzeni wierszowej $\mathbf{X}$, a składowa z jądra tej macierzy zostaje taka, jaka wypadła w losowaniu. Granicą treningu jest

$$\mathbf{w}_\infty = \mathbf{w}_0 + \mathbf{X}^+ \left(\mathbf{t} - \mathbf{X}\mathbf{w}_0\right), \tag{2}$$

gdzie $\mathbf{X}^+$ jest pseudoodwrotnością $\mathbf{X}$. Wpływ wag początkowych zależy więc od wymiaru jądra, czyli od rzędu macierzy [3]. Krok uczący przyjęto jako $\eta = 0{,}1$, wspólny dla wszystkich eksperymentów. Przy stałym kroku reguła przyrostowa nie zatrzymuje się dokładnie w punkcie granicznym, lecz w jego otoczeniu o promieniu rzędu η [2]; obciążenie to jest widoczne w wynikach jako niewielka odchyłka od wartości przewidzianej (2).

3 Eksperymenty i wyniki

We wszystkich eksperymentach stosowano przyrostową regułę delty: wagi poprawiano po każdym wzorcu, a jedynym kryterium zatrzymania była

liczba epok $K = 20000$. Zbiór treningowy losowano *raz* dla danej konfiguracji, a wagi początkowe *osobno dla każdego przebiegu*, z rozkładu jednostajnego na $[-1, 1]$. Wartości $\mathbf{X}$ i $\mathbf{t}$ pochodzą z rozkładu $\mathcal{N}(0, 1)$, przy czym $\mathbf{t}$ losowano niezależnie od $\mathbf{X}$: przyjęcie $\mathbf{t} = \mathbf{X}\mathbf{w}$ czyniłoby układ zgodnym także dla $M > N$ i usuwało najistotniejszy z badanych przypadków.

3.1 Eksperyment nr 1: układ nadokreślony ($N < M$)

3.1.1 Założenia

Neuron o $N = 3$ wagach trenowany na $M = 10$ wzorcach, a więc więcej równań niż niewiadomych. Rząd macierzy $\mathbf{X}$ wynosi 3, krok uczący $\eta = 0{,}1$. Wykonano 8 przebiegów.

3.1.2 Przebieg

Każdy przebieg rozpoczynał się od innych wag losowych i obejmował K epok na tym samym zbiorze treningowym. Po każdej epoce rejestrowano błąd średniokwadratowy na całym zbiorze, wyłącznie w celach pomiarowych.

3.1.3 Rezultat

Wagi końcowe wszystkich przebiegów zestawiono w Tab. 1.

Tabela 1: Wagi końcowe w ośmiu przebiegach dla $N = 3$, $M = 10$

Przebieg	w_1	w_2	w_3	**Błąd MSE**
1	0,4185	−0,2131	−0,3128	4,962e−01
2	0,4185	−0,2131	−0,3128	4,962e−01
3	0,4185	−0,2131	−0,3128	4,962e−01
4	0,4185	−0,2131	−0,3128	4,962e−01
5	0,4185	−0,2131	−0,3128	4,962e−01
6	0,4185	−0,2131	−0,3128	4,962e−01
7	0,4185	−0,2131	−0,3128	4,962e−01
8	0,4185	−0,2131	−0,3128	4,962e−01

Wagi są nieodróżnialne we wszystkich przebiegach, a rozrzut $5{,}551 \cdot 10^{-17}$ leży na poziomie precyzji arytmetyki zmiennoprzecinkowej. Błąd końcowy

0,4962 wobec granicy najmniejszych kwadratów 0,492861 pozostawia różnicę 0,003, która wynika z omówionego wyżej obciążenia reguły przyrostowej, a nie z nieskuteczności treningu. Skuteczny trening nie był możliwy: przy losowym $\mathbf{t}$ układ dziesięciu równań o trzech niewiadomych jest sprzeczny, a najlepszy kompromis jest tylko jeden.

3.2 Eksperyment nr 2: układ kwadratowy ($N = M$)

3.2.1 Założenia

Neuron o $N = 5$ wagach i $M = 5$ wzorców, rząd macierzy $\mathbf{X}$ równy 5, krok uczący $\eta = 0{,}1$, 8 przebiegów.

3.2.2 Przebieg

Jak w eksperymencie nr 1.

3.2.3 Rezultat

Wyniki przedstawia Tab. 2.

Tabela 2: Wagi końcowe w ośmiu przebiegach dla $N = 5$, $M = 5$

Przebieg	w_1	w_2	w_3	w_4	w_5	**Błąd MSE**
1	−1,2188	−0,1165	−0,2026	0,6470	−1,4753	1,006e−29
2	−1,2188	−0,1165	−0,2026	0,6470	−1,4753	1,006e−29
3	−1,2188	−0,1165	−0,2026	0,6470	−1,4753	1,006e−29
4	−1,2188	−0,1165	−0,2026	0,6470	−1,4753	1,006e−29
5	−1,2188	−0,1165	−0,2026	0,6470	−1,4753	1,006e−29
6	−1,2188	−0,1165	−0,2026	0,6470	−1,4753	1,006e−29
7	−1,2188	−0,1165	−0,2026	0,6470	−1,4753	1,006e−29
8	−1,2188	−0,1165	−0,2026	0,6470	−1,4753	1,006e−29

Wagi końcowe są nieodróżnialne, rozrzut wynosi dokładnie zero, a błąd spada do $1{,}0 \cdot 10^{-29}$. Macierz $\mathbf{X}$ jest nieosobliwa, więc układ ma dokładnie jedno rozwiązanie i algorytm zbiega do niego niezależnie od punktu startowego. Jest to jedyna konfiguracja, w której trening jest zarazem skuteczny i jednoznaczny.

3.3 Eksperyment nr 3: układ niedookreślony ($N > M$)

3.3.1 Założenia

Neuron o $N = 10$ wagach i tylko $M = 4$ wzorcach. Rząd macierzy $\mathbf{X}$ wynosi 4, więc jądro ma wymiar $10 - 4 = 6$. Krok uczący $\eta = 0{,}1$, 8 przebiegów.

3.3.2 Przebieg

Jak poprzednio. Dodatkowo, dla każdego przebiegu sprawdzano zgodność wag końcowych z granicą przewidzianą równaniem (2) oraz badano, czy różnice między przebiegami leżą w jądrze macierzy $\mathbf{X}$.

3.3.3 Rezultat

Wagi końcowe zestawiono w Tab. 3; ze względu na liczbę wag tabelę podano w układzie transponowanym.

Tabela 3: Wagi końcowe w ośmiu przebiegach dla $N = 10$, $M = 4$

	Przebieg							
Waga	1	2	3	4	5	6	7	8
w_1	−1,148	−0,932	−0,322	−0,932	−0,995	−0,444	−0,359	−1,289
w_2	0,232	0,688	0,263	0,310	0,140	0,353	0,176	−0,101
w_3	0,865	−0,453	0,213	0,340	0,735	0,103	0,847	0,507
w_4	−0,003	0,334	−0,124	0,490	0,041	0,180	0,174	−0,521
w_5	−0,120	0,579	0,832	0,652	0,491	1,079	1,356	0,569
w_6	0,159	−0,853	−0,163	0,246	−0,273	−0,049	0,222	1,070
w_7	0,428	−0,315	0,437	0,668	−0,350	0,263	−0,196	−0,373
w_8	−0,516	−0,441	−1,332	0,635	0,479	−0,748	−0,809	0,420
w_9	−0,303	0,777	0,312	0,337	0,697	0,467	0,295	0,591
w_{10}	−0,423	0,317	0,071	−0,625	−1,196	0,482	1,081	−0,300

Tym razem wagi końcowe różnią się w każdym przebiegu. Rozrzut wynosi 2,276, a więc tyle, ile same wagi. Mimo to błąd końcowy spada do $5{,}9 \cdot 10^{-32}$ w każdym przebiegu, czyli trening jest skuteczny, lecz rozwiązanie nie jest jedyne. Zestawienie miar kontrolnych dla trzech pierwszych eksperymentów zawiera Tab. 4.

Najistotniejszy jest ostatni wiersz Tab. 4: wagi różnią się między przebiegami o 2,276, lecz po przemnożeniu różnic przez $\mathbf{X}$ wychodzi zero z do-

Tabela 4: Miary kontrolne dla trzech badanych konfiguracji

Wielkość	$N < M$	$N = M$	$N > M$
Rozrzut wag między przebiegami	5,55e−17	0,00e+00	2,28e+00
Błąd końcowy MSE	4,96e−01	1,01e−29	5,93e−32
Granica najmniejszych kwadratów	0,492861	0,000000	0,000000
Odchyłka od granicy (2)	4,40e−02	2,13e−14	2,44e−15
$\|\mathbf{X}(\mathbf{w}_i - \mathbf{w}_1)\|$	8,64e−17	0,00e+00	6,11e−16

kładnością do $6 \cdot 10^{-16}$. Przebiegi różnią się więc wyłącznie składową z jądra $\mathbf{X}$, czyli w sześciu kierunkach nieobjętych przez wzorce.

Zbieżność błędu we wszystkich trzech konfiguracjach przedstawia Rys. 1, a rozrzut wag końcowych Rys. 2.

Na Rys. 1 dla $N < M$ błąd osiada tuż nad granicą najmniejszych kwadratów (linia przerywana), a w pozostałych konfiguracjach opada o kilkanaście rzędów wielkości. Na Rys. 2 krzywe wag dla $N < M$ i $N = M$ pokrywają się z rozwiązaniem $\mathbf{X}^{+}\mathbf{t}$, a dla $N > M$ wyraźnie się rozchodzą.

3.4 Eksperyment nr 4: powtarzalność dla różnych losowań zbioru

3.4.1 Założenia

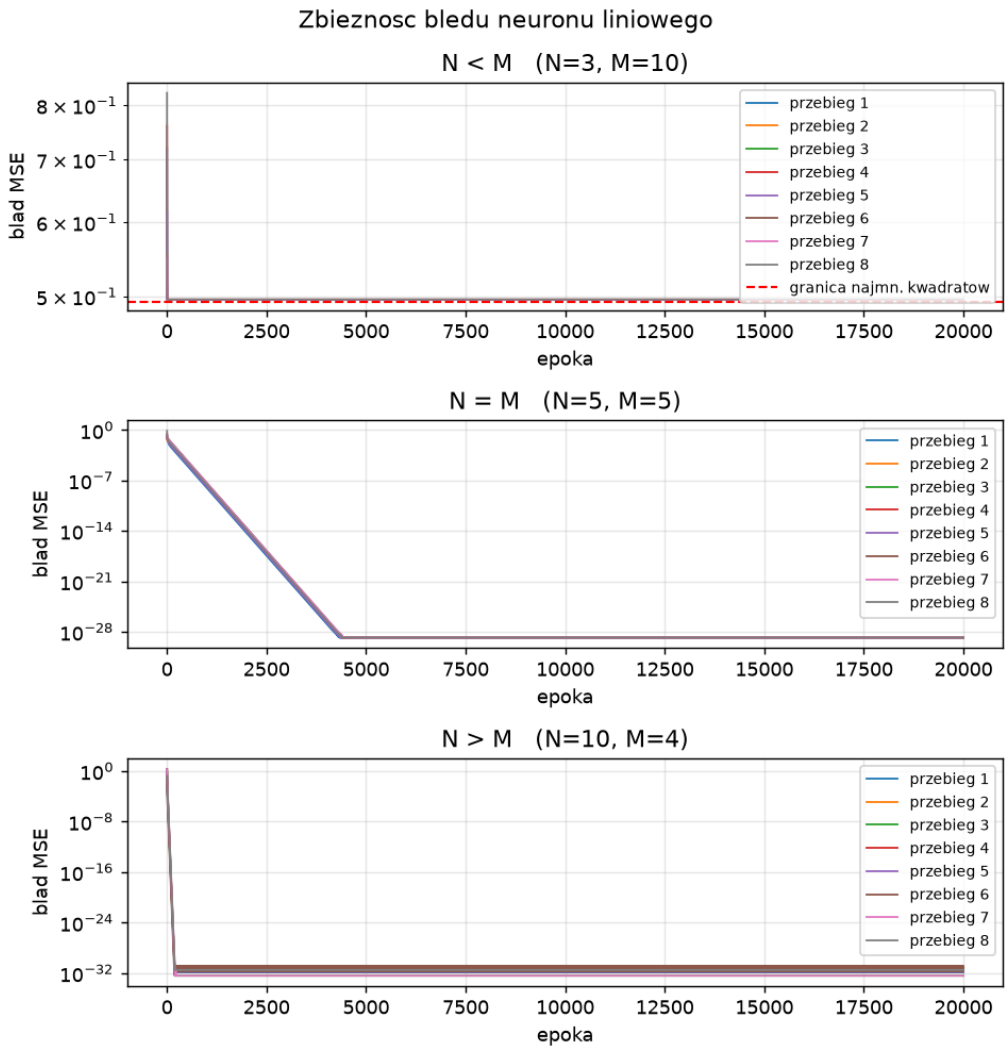
Jeden wylosowany zbiór treningowy nie wystarcza, aby mówić o prawidłowości, dlatego eksperymenty nr 1–3 powtórzono dla pięciu różnych ziaren losowania zbioru treningowego. Dla każdego ziarna i każdej z trzech konfiguracji wykonano 6 przebiegów treningu.

3.4.2 Przebieg

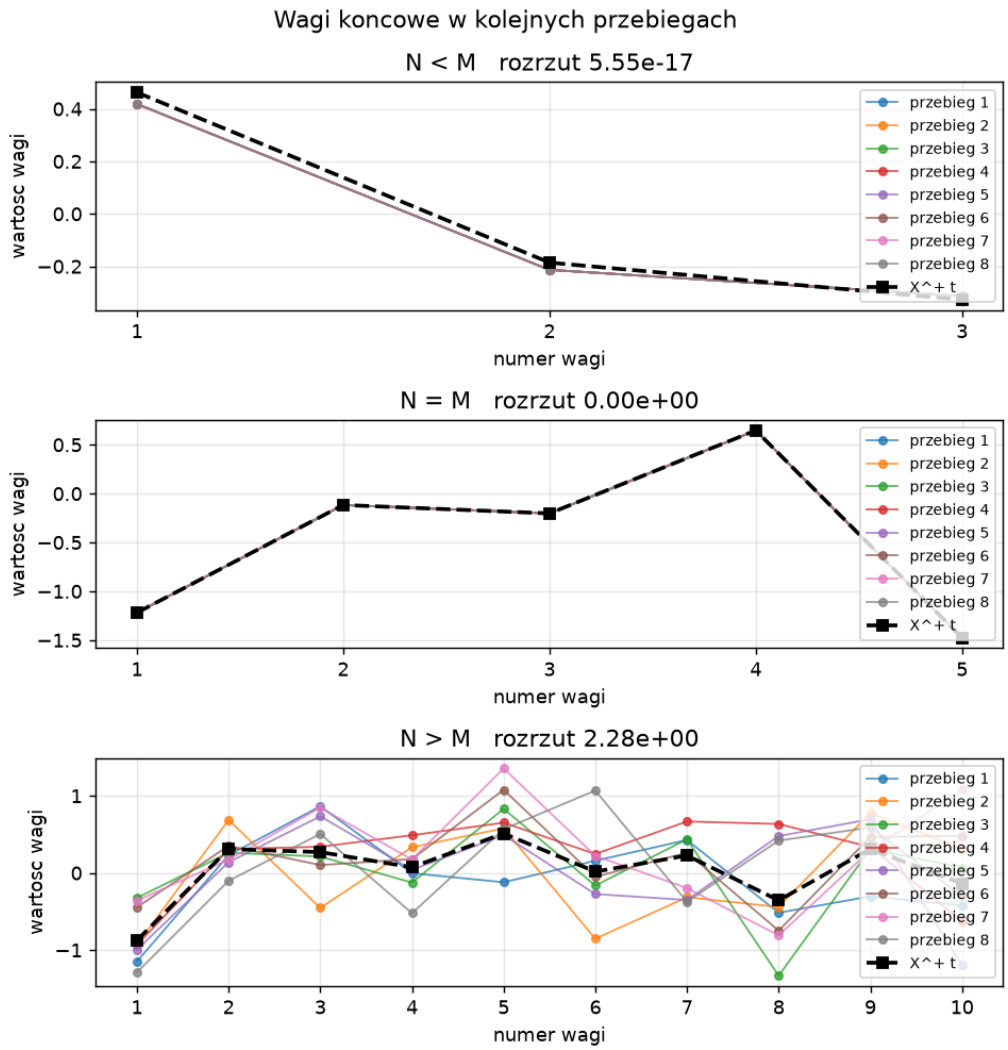
Dla ustalonego ziarna losowano zbiór $\mathbf{X}$ i $\mathbf{t}$, a następnie przeprowadzano sześć przebiegów od różnych wag początkowych, dokładnie tak jak w eksperymentach nr 1–3. Mierzono rozrzut wag końcowych między przebiegami oraz błąd końcowy.

3.4.3 Rezultat

Wyniki zestawiono w Tab. 5.



Rysunek 1: Zbieżność błędu średniokwadratowego w kolejnych przebiegach treningu



Rysunek 2: Wagi końcowe uzyskane w poszczególnych przebiegach na tle rozwiązania $\mathbf{X}^{+}\mathbf{t}$

Tabela 5: Rozrzut wag i błąd końcowy dla pięciu losowań zbioru treningowego

	rozrzut wag / błąd MSE		
Ziarno	$N < M$	$N = M$	$N > M$
2024	5,55e−17 / 4,96e−01	0,00e+00 / 1,01e−29	1,97e+00 / 5,01e−32
7	0,00e+00 / 4,60e−01	0,00e+00 / 6,58e−31	1,90e+00 / 3,45e−32
99	0,00e+00 / 8,27e−01	0,00e+00 / 9,76e−28	1,69e+00 / 4,70e−32
12345	4,44e−16 / 7,54e−01	0,00e+00 / 3,71e−29	1,72e+00 / 8,50e−32
555	8,33e−17 / 9,95e−01	3,55e−15 / 4,97e−30	1,97e+00 / 1,54e−32

Podział jest stabilny niezależnie od wylosowanego zbioru: dla $N < M$ i $N = M$ rozrzut wag nie przekracza $4{,}4 \cdot 10^{-16}$, a dla $N > M$ mieści się między 1,69 a 1,97, czyli jest tego samego rzędu co same wagi. Różnica kilkunastu rzędów wielkości wyklucza przypadkowość obserwacji. Błąd końcowy dla $N < M$ zmienia się ze zbiorem (od 0,46 do 0,99), bo zależy od stopnia sprzeczności układu, ale nigdy nie spada do zera.

4 Wnioski

Prawidłowości w wagach końcowych. Są wyraźne i skrajnie różne w trzech badanych konfiguracjach. Dla $N < M$ oraz $N = M$ wagi końcowe są nieodróżnialne we wszystkich przebiegach. Rozrzut rzędu 10^{-17}, a dla $N = M$ dokładnie zerowy, oznacza, że punkt startowy nie ma żadnego znaczenia. Dla $N > M$ każdy przebieg kończy się innym zestawem wag, przy rozrzucie tego samego rzędu co same wagi. Różnice te nie są jednak przypadkowe: leżą dokładnie w jądrze macierzy $\mathbf{X}$, a więc wyłącznie w kierunkach obojętnych dla zbioru treningowego.

Skuteczność treningu. Skuteczny trening okazał się możliwy w dwóch z trzech przypadków. Dla $N = M$ i $N > M$ błąd spadł odpowiednio do 10^{-29} i 10^{-32}, czyli do zera w granicach precyzji obliczeń. Dla $N < M$ trening skuteczny nie był możliwy, ponieważ błąd zatrzymał się na wartości 0,4962, przy błędzie rozwiązania najmniejszych kwadratów równym 0,492861, którego z matematycznego punktu widzenia nie da się zmniejszyć.

Interpretacja. Trening neuronu jest równoważny rozwiązywaniu układu (1) o M równaniach i N niewiadomych. Dla $N < M$ układ jest nadokreślony, ponieważ równań jest więcej niż niewiadomych. Rozwiązanie dokładne nie istnieje, więc błąd nie spada do zera. Dla $N = M$ układ ma dokładnie jedno rozwiązanie, więc wagi końcowe są zawsze takie same. Dla $N > M$ układ jest niedookreślony, ponieważ równań jest mniej niż niewiadomych. Rozwiązań jest nieskończenie wiele, więc każdy przebieg kończy się innymi wagami.

Doprecyzowanie. Z równania (2) wynika, że o wyniku decyduje nie samo porównanie N z M, lecz rząd macierzy $\mathbf{X}$: liczba stopni swobody pozostających neuronowi po treningu to wymiar jądra, czyli $N - \operatorname{rank}(\mathbf{X})$. Prawidłowość można więc sformułować ogólniej:

- $\operatorname{rank}(\mathbf{X}) = N$ oznacza rozwiązanie jednoznaczne,
- $\operatorname{rank}(\mathbf{X}) < N$ oznacza nieskończenie wiele rozwiązań zależnych od punktu startowego,
- $\operatorname{rank}(\mathbf{X}) < M$ oznacza układ na ogół sprzeczny.

Z praktycznego punktu widzenia najbardziej pouczający jest przypadek $N > M$: zerowy błąd na zbiorze treningowym nie oznacza, że model został wyznaczony. Pozostaje sześć wymiarów swobody, o których dane nie mówią nic. Jest to ta sama sytuacja, co przeuczenie modelu o nadmiarowej liczbie parametrów.

5 Załączniki

Rdzeń implementacji, czyli pętla realizująca kroki 4–10 algorytmu treningowego (plik `linear_neuron.py`):

```
for k in range(epochs):                          # krok 4: dopoki k < K
    for x, z in zip(X, t):                       # kroki 5, 6, 9: mu = 1..M
        neuron.forward(x)                        # krok 7: y = w.x
        neuron.back_propagation(
            mean_squared_error_derivative(
                np.array([z]), neuron.activations[-1]))
        neuron.update_weights(learning_rate / 2.0, 0)   # krok 8
    errors[k] = float(np.mean((X @ weights(neuron) - t) ** 2))
```

Krok uczący przekazywany jest jako $\eta/2$, ponieważ użyta pochodna błędu średniokwadratowego wnosi czynnik 2; efektywna poprawka wag jest zatem dokładnie równa $\eta\,(z-y)\,x_i$.

Bibliografia

[1] K. Stokfiszewski. *Inteligentna Analiza Danych. Materiały do wykładu nr 1.* Instytut Informatyki Politechniki Łódzkiej.

[2] B. Widrow, M. E. Hoff. *Adaptive switching circuits.* IRE WESCON Convention Record, 1960.

[3] S. Osowski. *Sieci neuronowe do przetwarzania informacji.* Oficyna Wydawnicza Politechniki Warszawskiej, Warszawa.